

Rebalanceo de Ecobici con información asimétrica: asignación cada 15 minutos contra lo que Ecobici hace de verdad

Jerónimo Deli

Ciencia de Datos Aplicada, ITAM — Caso de titulación
septiembre de 2026

Resumen—Ecobici no publica su flota, sus rutas ni sus turnos; solo publica un feed de disponibilidad por estación y, cada mes, los viajes. Con esa información asimétrica preguntamos si una política de asignación que decide cada 15 minutos cuántas bicis poner o quitar en cada estación reduce los minutos-estación vacíos y llenos (E+F) respecto a lo que Ecobici hace hoy, con un esfuerzo comparable. Primero reconstruimos el rebalanceo real de Ecobici, estación por estación, cruzando el stock del feed con los viajes. Separamos taller, daños y reparaciones, y quitamos el ruido de sincronía. Ese rebalanceo inferido se reproduce en un simulador viaje por viaje que valida contra el feed: E queda dentro de 6.6 % en la mañana y F dentro de 5.0 % en el día, pero E del día completo queda 14.1 % abajo, fuera del criterio de 10 % (aunque no del umbral grave de 25 %). Ahí compiten, con los mismos viajes, las mismas dañadas y topes de esfuerzo medidos de Ecobici, varios pronósticos acoplados a un MILP de horizonte móvil. Todo se eligió en 15 días de selección y se reporta en otros 15 días de evaluación (sep–nov 2025, 05:30–00:30). Con un pronóstico emitido una sola vez a las 05:30, el asignador baja E+F 55 % contra Ecobici, gana los 15 días y hace casi los mismos movimientos (2,502 contra 2,416 por día). Re-pronosticar durante el día no ayuda. Con el pronóstico perfecto la mejora sube a 74 %: lo que falta por ganar es sobre todo pronóstico. El resultado vive en una app con el mapa en vivo, el replay de decisiones y la predicción del día. Código, app e instrucciones: <https://github.com/Jero110/movilidad-cdmx>.

Palabras clave—bicicletas compartidas, rebalanceo, GBFS, información asimétrica, MILP, horizonte móvil, simulación, Ecobici

I. CONTEXTO

El caso describe una ciudad donde más de 20 millones de personas se mueven en un sistema fragmentado, y donde casi todo el transporte concesionado opera sin registro. Lo interpretamos así: el problema útil está donde sí hay datos finos y un operador que puede actuar con ellos. Ecobici, el sistema de bicicletas públicas de la Ciudad de México, es el único modo que publica cada viaje (origen, destino, hora y bici) y el estado de cada estación casi en tiempo real. En 2025 tuvo 55,957 viajes por día en promedio, en 677 estaciones.

Ese estado cambia rápido. Las mañanas entre semana vacían las estaciones residenciales y llenan las de oficinas; en la tarde el patrón se invierte. Para sostener el servicio, Ecobici *rebalancea*: mueve bicis en camionetas de estaciones con sobra a estaciones con falta. Lo que se sabe de esa operación es parcial. Hay un equipo que monitorea la disponibilidad las 24 horas y coordina a “balanceadores” en camionetas con

capacidad de hasta 42 bicis cuando llevan remolque [1]. El territorio se divide en 123 subzonas de 3 a 5 estaciones y las órdenes llegan por app [2]. El gobierno reconoce que 17 % de las bicis está fuera de servicio y que el rebalanceo se reprogramará con “flujos de calor” por polígono [3]. No son públicos el número de camionetas, las rutas, los turnos ni la capacidad diaria de la operación.

I-A. Trabajo previo

El *bike rebalancing problem* (BRP) tiene una literatura amplia. En su versión **estática** (una vez, con el sistema cerrado) se formula como ruteo con inventarios [4; 5; 6]. Schuijbroek, Hampshire y van Hoesel [7] separan dos preguntas: qué inventario necesita cada estación y qué rutas lo consiguen. Por estación, la insatisfacción esperada como función del inventario inicial [8; 9; 10] es la idea detrás de nuestra función de costo. En la versión **dinámica** (durante el día) hay redes espacio-tiempo [11], reglas de prioridad [12], políticas con *lookahead* sobre demanda simulada [13] y comparaciones empíricas de estrategias [14]; la demanda estocástica aparece en [15]. El pronóstico de demanda por estación va de modelos jerárquicos [16] a predicción de sobredemanda por clústers [17].

Dos líneas tocan la **información incompleta**. La demanda observada está censurada: nadie renta en una estación vacía [18]. Y el rebalanceo del operador casi nunca es público, así que se infiere de datos abiertos, cruzando el estado de las estaciones con los viajes [19; 20]. Luo et al. encuentran, en tres sistemas de Estados Unidos, que la mayor parte del rebalanceo ocurre de día [20]. Para Ecobici hay trabajos del ITAM con datos de 2017–2018: ruteo mTSP y pronóstico por estación [21], inventario por simulación-optimización [22] e inventario y ruteo con programación lineal y estocástica [23].

Qué hacemos distinto. Casi toda esta literatura compara su política contra *no hacer nada* o contra una heurística sintética. Nosotros la comparamos contra el operador real, medido desde datos públicos y reproducido en el mismo simulador. Eso obliga a reconstruir el rebalanceo de Ecobici con cuidado (taller, daños, ruido del feed) y convierte la comparación en la pregunta central del trabajo.

II. DEFINICIÓN DEL PROBLEMA

Pregunta. Con solo la información pública (feed GBFS y viajes), ¿puede una política que decide cada 15 minutos cuántas bicis poner o quitar en cada estación reducir los minutos-estación vacíos y llenos respecto a lo que Ecobici hace hoy, con un esfuerzo comparable y bajo las mismas restricciones observables?

Por qué importa. En los 15 días de evaluación, el feed registra en promedio 99,047 minutos-estación vacíos y 17,770 llenos por día, entre 05:30 y 00:30. Una estación vacía es un viaje que no empieza o una caminata a otra estación; una llena obliga a buscar dónde dejar la bici. Además, Ecobici va a crecer de 9,308 a 15,000 bicis y de 687 a 1,111 estaciones [3], y con más estaciones el mismo equipo tiene más lugares que atender. La pregunta es alcanzable: todo lo que usa la política (estado cada 15 minutos, viajes históricos) es público.

Asimetría. No conocemos la flota, las rutas, los turnos, la bodega ni el taller. La tratamos así: (i) inferimos lo que Ecobici hizo, estación por estación, y lo reproducimos como *replay*; (ii) acotamos nuestro esfuerzo con topes medidos de Ecobici (movimientos por hora, bicis por movimiento, bodega); (iii) comparamos todo en el mismo simulador, con los mismos viajes y las mismas dañadas. Así la comparación es lo más **justa** y lo más **robusta** que permiten los datos. Robusta quiere decir que la conclusión no cambia en ninguna sensibilidad.

Alcance. Decidimos *asignación*: cuántas bicis poner o quitar en cada estación, cada 15 minutos, con efecto una hora después. No decidimos rutas ni camiones. El periodo es septiembre a noviembre de 2025, en el horario de servicio (05:30–00:30).

Métrica. E y F son los minutos-estación con 0 bicis disponibles (E) o con 0 anclajes libres (F), contados minuto a minuto y sin las estaciones fuera de servicio. El esfuerzo se mide en movimientos (una orden en una estación) y en bicis movidas.

Hipótesis, formuladas antes de modelar. H1: Ecobici rebalancea todo el día y no solo de noche. H2: con pronóstico perfecto, el asignador gana a Ecobici con igual o menor esfuerzo; si no, el enfoque no sirve. H3: con pronósticos reales también gana. H4: re-pronosticar durante el día con lo observado mejora contra un pronóstico único de las 05:30. H5: casi toda la brecha que queda contra el pronóstico perfecto es error de pronóstico, no del optimizador. Al final reportamos cuáles se sostienen.

III. SUPUESTOS

La Tabla I lista los supuestos, por qué valen aquí y qué cambiaría si fallan. Los marcados con ✓ se verificaron con datos (sección *Resultados y discusión*).

Tabla I: Supuestos del planteamiento (P), de los datos (D) y del modelo (M).

	Supuesto, por qué es válido aquí y qué pasa si cambia
P1	E y F pesan igual. Ecobici prioriza vacías en su discurso, pero un usuario que no puede anclar también pierde el viaje. Si E pesara más, se pondera en la función de costo sin cambiar nada más.
P2	Se decide asignación y no rutas, porque la flota no es pública. El esfuerzo se acota con topes medidos de Ecobici. Si la flota real no alcanza, la ventaja se reduce (ver Conclusiones).
P3	Los viajes son exógenos: una salida en una estación vacía se desvía a la más cercana con bici ($a \leq 500$ m si la hay) y no se pierde. No modelamos la demanda censurada, así que E subestima el daño real de una vacía [18].
P4	Ecobici es lo que inferimos del feed. Es simulador contra simulador, y hay sesgos en los dos sentidos: el replay en t_0 y los topes que solo aplican a las políticas favorecen a Ecobici; quitar los pares ± 1 y que la política vea el estado exacto la favorecen a ella. ✓ V1 y las sensibilidades los miden.
D1	El estado del feed es ~ 30 s anterior a la hora de su <i>commit</i> . ✓ El cuadre stock-viajes es máximo con un desfase de +30 a +36 s.
D2	Todo cambio de stock que no explican los viajes es intervención de Ecobici (sin umbral). Dos toques a una estación en el mismo intervalo se ven como uno.
D3	Un par ± 1 que se deshace en el intervalo siguiente es ruido de sincronía y no rebalanceo. ✓ Son 46.5 % de los intervalos con cambio; quitarlos casi no mueve E+F.
D4	Las bicis reparadas que vuelven del taller no se distinguen de un "poner" de rebalanceo. Esto infla la bodega medida (632 contra 74 con el taller dentro); ver la sensibilidad.
D5	Una estación que reporta todo en cero está fuera de servicio. ✓ No hay viajes mientras reporta en blanco.
D6	Sep–nov 2025 es representativo de un día normal (sin vacaciones de verano ni diciembre). Diciembre 2025 está sellado como reserva y no se leyó.
M1	Para decidir, la demanda es un flujo fluido con tasa uniforme dentro de cada bloque de 60 min. ✓ El costo sustituto ordena los planes como el simulador (Spearman mediana 0.977).
M2	Una orden tarda $L = 60$ min en hacerse efectiva. Sensibilidad con 45 y 30.
M3	El asignador ve el estado exacto cada 15 min, como lo da el feed en vivo.
M4	Las dañadas, los daños y el taller son eventos exógenos, iguales en todos los brazos. ✓ El simulador sigue a las dañadas del feed con error de 0.04 por estación.

IV. RESULTADOS Y DISCUSIÓN

IV-A. Datos

Usamos tres fuentes. (i) **Viajes**: datos abiertos de Ecobici [24], enero a noviembre de 2025; cada renglón trae bici, estación y hora de salida y de llegada. (ii) **Feed GBFS en vivo** [25]: el estado de cada estación (bicis disponibles, dañadas, anclajes libres y deshabilitados, *is_renting*). El feed declara *ttl* de 10 s y, en una muestra del 29 de septiembre de 2026, *last_updated* avanzó cada ~ 10 –11 s. La app lo lee en vivo. (iii) **Histórico del feed: agradecemos a Max Halford**, cuyo repositorio *bike-sharing-history* [26] consulta desde 2023 los feeds de decenas de sistemas, “aproximadamente cada 12 minutos” según su README, y publica archivos mensuales. Los de Ecobici empiezan en abril de 2024. Sin ese archivo no habría forma de saber qué hizo Ecobici en el pasado. Usamos agosto a noviembre de 2025 en la ventana 05:00–01:00: 5,730,807 renglones en 121 días. **Diciembre de 2025 está sellado para el experimento final**: se reservó como conjunto de prueba final y ningún código de la tubería *ecosim* lo puede leer (el 30 de noviembre también queda fuera, porque su ventana llega al 1 de diciembre). Un análisis exploratorio anterior y ajeno a esta tubería sí abarcó 2025–2026; se identifica explícitamente abajo y no se usó para seleccionar ni evaluar modelos.

Checks de validación (lo primero que hicimos). La Tabla II resume los datos, recalculados con `report/figs/checks_datos.py`. Los archivos de viajes

están particionados por mes de llegada, sin duplicados ni timestamps inválidos. Los viajes usan 677 estaciones con identificador numérico, como el feed (677 a 679 por día); solo dos identificadores no numéricos (una estación temporal y el 1000) quedan fuera.

Tabla II: Checks de los datos (viajes ene–nov 2025; feed ago–nov 2025).

Viajes (ene–nov 2025)	18,689,701
Estaciones / bicis distintas	677 / 7,966
Viajes por día: media (mediana)	55,957 (60,924)
entre sem. / fin de sem. / festivo	63,707 / 38,766 / 31,366
mín. (2025-01-01) / máx. (2025-02-27)	16,643 / 75,347
Viajes por semana (47 completas)	393,809
mínimo / máximo	322,605 / 449,325
Máx. viajes en una hora (2025-01-28 18:00)	7,377
Duración: mediana / p95 (min)	11.9 / 36.7
Viajes/día 00:00–00:30 / 00:30–05:00	223 / 0.6
Commits del feed por día (05:00–01:00)	70
Hueco entre snapshots, mediana / p90 (min)	15.9 / 23.6
mediana 18:00–21:59 / resto del día	35.6 / 15.3
Rentan: 00:00–00:30 / 00:30–01:00	99.8 % / 1.4 %
Disponibles: antes / después de 00:30	5,442 / 91

Tres hallazgos guían el modelado. (1) Entre semana hay dos picos, a las 8 y a las 18 h, con 5,550 salidas por hora a las 18 h; el fin de semana tiene un solo pico al mediodía (Figura 1). Por eso los pronósticos distinguen el tipo de día. (2) **A las 00:30 el sistema cierra:** el feed pasa a no rentar (1.4 % de las estaciones rentan después de las 00:30, contra 99.8 % antes) y reporta las bicis ancladas como dañadas (1,404 → 6,826). Entre 00:30 y 05:00 hay 0.6 viajes por día. Esto fija la ventana en 05:30–00:30. (3) El recolector es irregular de 18:00 a 21:59: el hueco mediano entre snapshots sube de 15.3 a 35.6 min (Figura 2). Por eso la cobertura de un día se mide con bloques de 60 min (se exige $\geq 90\%$) y no de 15. Además, esa franja es donde la medición de Ecobici es menos precisa.




Figura 1: Salidas por hora del día, media por día (ene–nov 2025).




Figura 2: Hueco mediano entre snapshots del histórico, por hora (ago–nov 2025). En rojo, 18:00–21:59.

IV-B. Cómo medimos el rebalanceo de Ecobici

Primer enfoque: seguir cada bici. Si una bici termina un viaje en la estación A y su siguiente viaje sale de $B \neq A$, alguien la movió. Así contamos 2.78 millones de “saltos” en un análisis exploratorio anterior al experimento, sobre ene-2025–ago-2026 (wiki/Rebalanceo-Ecobici-suposicion-horario.md). Ese conteo incluye el mes reservado y por ello solo motiva el método: no entra en los datos, parámetros ni resultados del run 2. El método tiene dos fallas de fondo. Solo sabemos que la bici se movió entre su llegada a A y su siguiente salida de B; si nadie la toma pronto, no sabemos *cuándo* llegó (el hueco mediano es de 2.3 h). Y nunca vemos las bicis que Ecobici mete desde bodega o taller, porque no tienen viaje anterior.

Enfoque final: inferencia por estación. Entre dos snapshots consecutivos $t_0 < t_1$ de la estación i ,

$$\delta_i = s_i(t_1) - s_i(t_0) - \text{llegadas}_i(t_0, t_1] + \text{salidas}_i(t_0, t_1],$$

con s = disponibles + dañadas, para que una bici que se marca dañada no parezca retirada. Todo $\delta \neq 0$ es una intervención de Ecobici (regla 1.3 del plan del run 1). Cuatro correcciones, cada una medida:

- **Hora.** El feed no trae last_reported. Al barrer desfases entre el reloj del feed y el de los viajes, el cuadro es máximo con +30 a +36 s, así que la hora de cada snapshot es la del commit menos 30 s.
- **Taller, daños y reparaciones.** Con Δd = cambio de dañadas: un aumento es *daño*; una baja con $\delta < 0$ es *taller* (Ecobici se lleva dañadas) hasta $\min(-\Delta d, -\delta)$, y el resto es *reparación en sitio*. El rebalanceo es $\delta^{\text{reb}} = \delta + \text{taller}$. En promedio hay 2,562 daños, 1,865 reparaciones y 657 bicis al taller por día. Los daños y el taller pasan al simulador como eventos exógenos.
- **Pares ± 1 que se deshacen.** Un +1 seguido de un −1 en el intervalo siguiente (o al revés) es desfase entre relojes, no un camión. Son 46.5 % de los intervalos con cambio y se excluyen de la medición principal.
- **Cierre de las 00:30.** El intervalo que cruza el cierre no genera movimientos.

En 120 días medidos, Ecobici hace 2,246 movimientos por día (4,404 con los pares ± 1), mete 5,674 bicis y saca 5,043. **H1 se confirma** (Figura 3): 44 % de los movimientos

ocurren de 05:30 a 12:30, 35 % de 12:30 a 18:30 y 20 % de 18:30 a 00:30. Hay picos a las 08:30–10:30 y a las 17:30. Esto corrige un supuesto que usamos al principio (wiki/Rebalanceo-Ecobici-suposicion-horario.md): que el rebalanceo era sobre todo nocturno. Coincide con lo que reportan Luo et al. para otros sistemas [20].




Figura 3: Rebalanceo inferido de Ecobici por bloque de 60 min (media de 120 días, sin taller ni pares ± 1).

IV-C. Decisiones tomadas con datos

La Tabla III resume cada parámetro con su número y su fuente. Tres merecen detalle.

Tope de bicis por movimiento (14/22/42). 42 es la capacidad de una camioneta con remolque [1]: el único límite físico público. 14 y 22 salen de las visitas de Ecobici. Lo recalculamos en report/figs/rebalanceo_ecobici.py. **En la mañana del run 1** (05:30–12:30, 15 días de evaluación, sin pares ± 1), 14 es el **p95** y 22 el **p99** exactos: la creencia de partida es correcta para esa medición. **En el día completo del run 2**, con la medición principal (sin taller y sin ± 1), el p95 sigue en 14 pero el p99 es 24: 22 queda en el percentil 98.7. Solo 0.26 % de las visitas de Ecobici pasa de 42 (Figura 4). Se usó 22 como principal y 14 y 42 como sensibilidad.




Figura 4: Bicis por movimiento de Ecobici, día completo, sin taller ni pares ± 1 (escala log; ≥ 60 se agrupa en 60).

Topes por hora (246) y de bodega (632). El tope por hora es el p95 de los movimientos de Ecobici en ventanas móviles de 60 min (mediana 113, máximo 1,165, un día atípico). La bodega es el promedio diario de $|A - R|$ del rebalanceo: 631.0, positivo los 120 días. Su limitación es seria. Con el taller dentro,

$A - R$ es -25.6 por día y el tope sería 74. La diferencia son reparadas que vuelven y que no podemos distinguir de bicis de bodega (D4). Por eso reportamos ambos.

λ por Kneedle. λ es el costo, en minutos-estación, de cada movimiento. Se eligió con Kneedle [27] sobre la curva E+F contra movimientos del oracle en días de selección: $\lambda = 60$. Pero λ es una **decisión operativa, no un parámetro estadístico** (Figura 5). Con $\lambda = 5$, el oracle da 13,079 de E+F con 3,272 movimientos; con $\lambda = 60$ da 33,917 con 1,642. Es decir, 2.6 veces menos E+F moviendo 2.0 veces más. A **igual número de movimientos que Ecobici** (2,315 por día en selección), $\lambda = 30$ hace 2,338 movimientos y deja 17,424 de E+F, contra 90,034 de Ecobici en los mismos días. El λ correcto depende de cuántas visitas por hora puede hacer la flota real, que no conocemos. λ bajo también cuesta cómputo: con $\lambda = 5$ una decisión llegó a tardar 333 s, contra 3.9 s como máximo en los brazos principales.




Figura 5: Curva de λ del oracle ($h=2$, $L=60$) en días de selección; el círculo es el λ de Kneedle y la estrella, el replay de Ecobici en los mismos días.

Tabla III: Parámetros, su valor y de dónde salen.

Decisión	Valor	Evidencia
Ventana	05:30–00:30	cierre a las 00:30 (Tabla II)
Días	15 + 15	selección y evaluación, estratificados 11 entre semana + 4 fin de semana; cobertura $\geq 90\%$
Bicis por movimiento	22 (14, 42)	p99/p95 de Ecobici (mañana); 42 = camioneta
Tope por hora	246	p95 de Ecobici sin ± 1 (con ± 1 : 474)
Bodega	632 (74)	[media $ A - R $] sin taller (con taller)
Dañadas	dinámicas	494,190 eventos del feed
Cota de retiro	$[p - \sigma]$	mejor en 84 de 105 pares (λ , día) de selección
λ	60	Kneedle sobre el oracle (selección)
h, f	por brazo	rejilla en selección (Tabla IV)
L	60 min	principal; 45 y 30 como sensibilidad

IV-D. Método

Simulador viaje por viaje (ecosim/sim.py). Arranca con el estado real de las 05:30 y nunca vuelve a leer el stock real: el estado cambia solo con los viajes, los eventos de dañadas y las órdenes. Una salida en estación vacía se desvía a la estación más cercana con bici (a ≤ 500 m si la hay); una llegada a estación llena, a la más cercana con lugar; ningún viaje se pierde. Cada orden se recorta a lo físicamente posible, a 22 bicis y a la bodega. El mismo motor y la misma métrica sirven para todos los brazos. El replay de Ecobici aplica δ^{reb} al

inicio de cada intervalo (t_0), lo que lo favorece; con t_1 como sensibilidad.

Pronósticos de salidas y llegadas por estación y bloque de 60 min (ecosim/pronostico.py). **oracle**: los conteos reales del día (techo). **daily**: media de los días del mismo tipo (entre semana o fin de semana/festivo) de las 4 semanas anteriores, emitida una sola vez a las 05:30 para todo el día. **ma**: la misma base, re-emitida cada $f \in \{15, 60, 180\}$ min y corregida con lo observado en el día, factor = $\text{clip}((\text{obs} + 5)/(\text{pred} + 5), 0.5, 2)$ por estación y dirección (el 5 se fijó antes de ver resultados). **model**: dos LightGBM Poisson [28] (salidas y llegadas) con estación (categórica), bloque, día de la semana, festivo, rezagos de 7 y 14 días y media de 28 días del mismo tipo de día. Se entrenan con 2025-01-01 a 2025-08-31, sin tunear (200 árboles, tasa 0.05, 31 hojas), y llevan la misma corrección. Un test verifica que ninguna emisión use datos posteriores a su hora.

Asignador (ecosim/asignador.py): MILP resuelto con HiGHS [29] en horizonte móvil. En cada t (cada 15 min) proyecta con un flujo fluido las bicis p_i que habrá en $t + L$. Para cada objetivo entero y calcula el costo $c_i(y)$: minutos vacíos más llenos en $[t + L, t + L + h)$ si la estación arranca con y bicis. Luego resuelve

$$\begin{aligned} \text{mín } & \sum_i z_i + \lambda \sum_i m_i + \mu w \\ \text{s.a. } & z_i \geq c_i(a) + \beta_{ik}(y_i - a) \quad (\text{envolvente convexa de } c_i) \\ & y_i - \hat{p}_i \leq u_i m_i, \quad \hat{p}_i - y_i \leq r_i m_i \\ & w \geq \pm \sum_i (y_i - \hat{p}_i), \quad \sum_i m_i \leq M_t \\ & \ell_t \leq \sum_i (y_i - \hat{p}_i) \leq h_t, \quad y_i \in \mathbb{Z}, \quad m_i \in \{0, 1\} \end{aligned}$$

con $\hat{p}_i = \text{round}(p_i)$ y las cotas por orden $r_i = \min(\lfloor p_i - \sigma_i \rfloor, 22)$ y $u_i = \min(K_i - \lceil p_i + \sigma_i \rceil, 22)$. Aquí σ_i es la desviación Poisson del flujo esperado en $[t, t + L)$ y K_i son las bicis más los anclajes libres. M_t es el tope por hora menos lo ya ordenado en las ventanas de 60 min que contienen a $t + L$, y $[\ell_t, h_t]$ mantiene la bodega acumulada en ± 632 . La orden es $x_i = y_i - \hat{p}_i$, efectiva en $t + L$. El detalle está en el Apéndice A. En 99,495 decisiones del run 2 no hubo ninguna sin solución factible, y una decisión tarda 0.34 s en promedio.

Protocolo. Todo lo elegible (cota de retiro, λ , h y la frecuencia f de cada brazo) se eligió en 15 días de **selección** y se congeló. Los resultados son de otros 15 días de **evaluación** (los del run 1). La métrica principal es E+F medio por día; también contamos en cuántos de los 15 días cada brazo le gana a Ecobici.

IV-E. Validación del simulador (V1)

Con el replay de Ecobici, el simulador reproduce E dentro de 6.6 % y F dentro de 2.8 % en la mañana (diferencia absoluta media por día), y F dentro de 5.0 % en el día. El error de stock es de 0.51 bicis por estación. En E del día completo queda 14.1 % abajo; en la tarde, 12.0 %, y en la noche, 23.4 %. El 42 % del faltante cae de 17:30 a 21:30: desde las 18:00 el recolector deja huecos de 20–45 min, y el replay en t_0 aplica cada movimiento al inicio del hueco, hasta 44 min antes de lo real. Con t_1 , E queda en 5.3 %. **Los sesgos van en los dos sentidos.** A favor de Ecobici: el replay en t_0 le baja E+F (con

t_1 sube 9 %, a 111,457), y la bodega y los topes solo limitan a las políticas. En su contra: quitar los pares ± 1 le sube 4 % (con ellos da 97,946), y la política ve el estado exacto. El error que queda con t_1 es del simulador y afecta a todos los brazos, sin dirección probada sobre la brecha. Las dañadas dinámicas arreglaron la falla del run 1: con dañadas fijas, E se desviaba 18.5 % en la mañana.

IV-F. Selección fuera de muestra

La Tabla IV muestra E+F en selección según h (cuántas horas mira el asignador, igual al horizonte del pronóstico). El oracle mejora hasta $h = 5$ y ma (re-emitido cada hora) hasta $h = 3$; se buscó hasta $h_{\text{máx}} = 6$. En la rejilla (f, h) , las mejores configuraciones fueron: daily con $h = 5$ (39,460), ma con $f = 15$, $h = 3$ (45,411) y model con $f = 15$, $h = 3$ (45,258). **H4 se rechaza.** El mejor brazo real es daily, que no re-pronostica. La exactitud lo explica: sobre las mismas decisiones, el MAE por estación-bloque de salidas es 2.053 con daily y 2.10 con ma re-emitido (ecosim/results/pronostico/REPORT.md). Con conteos tan chicos (WAPE ≈ 0.45), el factor por estación agrega más ruido que señal.

Tabla IV: E+F medio por día en selección (miles) según h .

h	1	2	3	4	5	6
oracle	126.5	33.9	25.9	22.8	21.5	21.6
ma ($f=60$)	127.5	50.6	45.9	46.8	49.7	52.4

IV-G. Brazos contra Ecobici (evaluación)

H2 y H3 se confirman (Tabla V, Figura 7). Todos los brazos le ganan a Ecobici los 15 días. daily baja E+F 55 % (entre 47 % y 62 % según el día) con 2,502 movimientos y 12,375 bicis por día, contra 2,416 y 11,067 de Ecobici: un esfuerzo comparable (4 % más movimientos, 12 % más bicis). El oracle baja 74 % con menos movimientos que Ecobici. ma y model ganan menos que daily, mueven más y saturan la bodega (recortan 639 bicis por día, contra 203 de daily); en una medición de integración en 4 días, la bodega explica cerca de un tercio de esa brecha. Con $L = 30$ min todo mejora: oracle 22,056, model 39,253.




Figura 7: E+F por día en evaluación, por brazo y franja.

H5 se confirma en parte. Entre daily y el oracle quedan 19,707 minutos-estación por día, y con el mismo optimizador




Figura 6: La app. Arriba a la izquierda: *Bicis ahora*, el feed en vivo. Arriba a la derecha: *Replay* del 3 de septiembre de 2025 a las 08:45 con el mejor brazo real (daily): órdenes del asignador, movimientos de Ecobici, insumos de la decisión y E+F acumulado. Abajo: *Predicción* con daily, el default final, sobre el feed real del 29 de septiembre de 2026 a las 17:30: qué mover ahora (232 movimientos, efectivos a las 18:30), estaciones en riesgo, de dónde sale cada número, viajes esperados y “qué tan bueno sería” (22 corridas ya evaluadas).

Tabla V: E+F por día en evaluación (miles de minutos-estación) por franja: mañana 05:30–12:30, tarde 12:30–18:30, noche 18:30–00:30. “Gana” = días con menos E+F que Ecobici. Bicis = miles movidas por día.

Brazo	Config.	E+F	Mañ.	Tarde	Noche	vs Eco.	Gana	Movs.	Bicis
Sin rebalanceo		250.8	74.6	74.6	101.7			0	0.0
Ecobici (replay)		102.2	38.6	28.5	35.1			2,416	11.1
oracle	h=5	26.6	12.0	7.8	6.8	−74 %	15/15	1,970	10.6
daily	h=5	46.3	16.4	15.1	14.8	−55 %	15/15	2,502	12.4
ma	f=15, h=3	53.0	19.0	17.5	16.5	−48 %	15/15	2,947	16.7
model	f=15, h=3	53.1	18.7	17.0	17.4	−48 %	15/15	2,948	16.7

la única diferencia es el pronóstico. Pero el oracle tampoco llega a cero, por razones que no son de pronóstico. La primera hora es intocable, porque la primera orden llega a las 06:30 (3,157, el 12 % del oracle). Y los hubs no alcanzan con una o dos visitas por hora.

Sensibilidades (Tabla VI). daily gana los 15 días en todas. Lo que más mueve el resultado es la bodega: con el tope de 74 (taller dentro), daily sube a 55,286. Le siguen el tope por movimiento (14: 48,018) y la cota de retiro. El tope por hora no aprieta: con 474, E+F cambia a lo más 1.4 %. $\lambda = 5$ ayuda mucho al oracle (19,816) pero casi nada a daily

(45,465 con 3,378 movimientos): con pronóstico imperfecto, las visitas extra persiguen ruido.

Tabla VI: Sensibilidades en evaluación: E+F (miles) y movimientos por día.

Cambio	oracle E+F	movs. daily E+F	movs. daily gana
Principal	26.6	1,970	46.3 2,502 15/15
Tope por movimiento 14	29.9	1,989	48.0 2,498 15/15
Tope por movimiento 42	25.3	1,958	45.9 2,511 15/15
Sin tope por movimiento	25.0	1,957	45.5 2,504 15/15
Tope por hora con ± 1 (474)	26.5	1,983	45.6 2,573 15/15
Dañadas fijas	21.7	1,799	41.5 2,344 15/15
Bodega ilimitada	23.0	1,808	40.7 2,237 15/15
Bodega con taller (74)	33.1	2,130	55.3 2,718 15/15
$\mu = 0$	26.2	1,982	46.9 2,517 15/15
Cota de retiro $\lfloor p \rfloor$	29.1	1,819	48.8 2,418 15/15
$\lambda = 5$	19.8	3,392	45.5 3,378 15/15
Todo como el run 1	17.9	1,678	36.8 2,181 15/15

Dónde falla. Las 20 peores combinaciones estación $\times$ hora de daily suman solo 1.6 % de su E+F: la falla está repartida. Destacan los hubs de la mañana (273-274, 271-272, 268-269 y 176 a las 07:30–08:30) y los vaciados de las 17:30–18:30 (261, 014, 022). En 273-274 a las 07:30, daily acumula 655 y el oracle 572, contra 112 de Ecobici. Ahí Ecobici opera una zona *valet* [2] con recargas continuas; nuestro pronóstico se queda corto en la punta (878 salidas pronosticadas contra 1,065 reales), y la estación estuvo vacía algún momento en 7 de los 15 días, así que la demanda observada está censurada.

Comparación con el run 1. El run 1 usó 05:30–12:30, dañadas fijas, bodega ilimitada, sin tope por movimiento y parámetros elegidos en los mismos días en que se evaluó. En la misma mañana, el run 2 da oracle 12,015 (run 1: 13,798) y daily 16,376 (run 1: 19,647), con reglas más estrictas y elección fuera de muestra (Tabla VII, Apéndice B). El replay de Ecobici con la regla del run 1 da exactamente los mismos 34,325, y con la medición justa sube a 38,611. Juntas, las decisiones del run 1 le daban al asignador 16–18 % menos E+F en la mañana (oracle 9,889, daily 13,719).

IV-H. Producto: la app

La app materializa el análisis para quien opera y para quien usa Ecobici (Figura 6). Es un solo servicio (FastAPI + MapLibre, `scripts/ecobici_mapa/`). El código, la app y las instrucciones de instalación y ejecución están en el repositorio público del proyecto [30]. Tiene tres pestañas centrales:

- **Bicis ahora:** las 677 estaciones con el feed GBFS en vivo, con bicis, estaciones sin bicis y sin lugar.
- **Replay:** para cada día de evaluación y cada brazo, rehace el día con el mismo motor y los parámetros congelados, y muestra cada 15 min el estado, los viajes, los órdenes del asignador (decididas y efectivas), los movimientos de Ecobici, los insumos de la decisión y el E+F acumulado contra Ecobici y sin rebalanceo. El E+F final de cada día y brazo coincide con `resultados.csv` (90 de 90 corridas, tolerancia 0).
- **Predicción:** con el feed real del día, qué mover ahora, qué estaciones están en riesgo y cuántos viajes se esperan; cuando pasa el horizonte, compara lo pronosticado contra lo observado en el feed y muestra el error acumulado. En 22 corridas evaluadas del 29 de septiembre con daily,

el MAE a 0 h fue de ≈ 2.2 salidas y 2.0 llegadas por estación-hora (hasta 2.4/2.2 a 3 h).

Pipeline en vivo. Un hilo del servidor lee el feed cada 60 s y lo guarda; cada 15 min arma el estado, pronostica con daily por defecto (el mejor brazo real del reporte; ma queda en el selector) y corre el asignador con los parámetros congelados ($\lambda = 60$, cota σ , $L = 60$ min, topes 246/h, bodega ± 632 , ≤ 22 bicis por movimiento). Como los viajes abiertos llegan a agosto de 2026, la base del pronóstico en vivo usa las 4 semanas que terminan el 30 de agosto de 2026, del mismo tipo de día.

V. CONCLUSIONES Y RECOMENDACIONES

Respuesta. Sí. Con solo datos públicos, una política de asignación cada 15 minutos con un pronóstico sencillo (el promedio de las 4 semanas anteriores, emitido a las 05:30) reduce E+F 55 % contra lo que Ecobici hizo, con un esfuerzo comparable. Gana los 15 días de evaluación y en todas las sensibilidades. Es un resultado de simulador, no un ahorro en la calle; la comparación es justa en todo lo que los datos permiten ver, y los sesgos que quedan son chicos frente a la brecha (el mayor, la hora del replay, mueve a Ecobici 9 %, contra una ventaja de 55 %).

Recomendaciones para Ecobici, en orden de prioridad.

1. **Piloto de asignación con el pronóstico daily en una microzona.** Es barato: usa el feed y los viajes que Ecobici ya tiene, y cada decisión tarda 0.34 s en promedio (3.9 s como máximo). Encaja con sus órdenes por app en 123 subzonas [2]. Medir E+F antes y después contra zonas testigo.
2. **Reducir el tiempo entre la decisión y la ejecución.** Pasar de 60 a 30 min baja E+F 17–26 % en nuestros brazos; es la palanca operativa más grande que medimos.
3. **Fijar λ por capacidad operativa, no por un codo estadístico.** λ traduce “cuánto vale una visita”. Con los datos de flota (camionetas por turno, visitas por hora), λ se calibra para usar exactamente esa capacidad.
4. **Separar taller y bodega en los datos que publica Ecobici.** La bodega es la sensibilidad que más mueve el resultado, y no la podemos medir bien (632 contra 74).
5. **No invertir primero en re-pronosticar ni en modelos complejos.** Re-emitir cada 15 min con corrección por estación no ayudó; model no le ganó a daily.

Supuestos que cambiarían las recomendaciones. Si la flota real no puede hacer 2,502 visitas diarias con picos de hasta 246 por hora, la ventaja se reduce. Si la bodega real se acerca a 74, daily sube 19 % y sigue ganando los 15 días. Si E importa más que F, hay que ponderar. Si la demanda censurada es grande en los hubs, el pronóstico subestima justo donde más importa.

Limitaciones y siguientes pasos. (i) Correr un año completo, con temporadas y vacaciones, y abrir la reserva de diciembre como prueba final. (ii) Re-entrenar el modelo por ventanas móviles y probar un factor intradía global, no por estación. (iii) Estimar la demanda censurada en hubs [18]. (iv) Agregar ruteo con una flota parametrizada [7] para verificar que las

órdenes son ejecutables. (v) Mejorar el replay de la noche con un feed más fino de 17:30 a 21:30. (vi) Decidir el estado de las 05:30 (rebalanceo nocturno), que hoy nadie controla en el simulador.

V-A. Uso de IA generativa

El código (ecosim/), los análisis y este reporte (repositorio [30]) se hicieron con agentes de Claude Code (Anthropic) bajo la dirección del autor. Cada módulo pasó por una revisión independiente hecha por otro agente. Cada número del reporte sale de un archivo o de un cálculo reproducible (report/fuentes-numeros.md); las citas se verificaron contra Crossref o contra la fuente.

AGRADECIMIENTOS

A Max Halford, por mantener bike-sharing-history [26]: sin su archivo histórico del feed no se podría medir lo que Ecobici hizo en el pasado.

REFERENCIAS

- [1] S. Navarrete, “En las entrañas de Ecobici: las personas que distribuyen 9,300 bicis a 687 estaciones en CDMX,” *Expansión Política*, <https://politica.expansion.mx/cdmx/2026/08/31/ecobici-personas-que-distribuyen-bicis-a-estaciones-en-cdmx>, 2026, 31 de agosto de 2026.
- [2] F. Mares, “Bikes, the foundation for cities’ smart mobility future: ECOBICI,” *Mexico Business News*, <https://mexicobusiness.news/mobility/news/bikes-foundation-cities-smart-mobility-future-ecobici>, 2026, 12 de agosto de 2026. Entrevista a Andrés Omaña, director de Operaciones de Ecobici.
- [3] F. Miranda, “CdMx expandirá Ecobici a Iztapalapa, Iztacalco y Tlalpan; ampliarán el sistema a 15 mil bicicletas,” *Milenio*, <https://www.milenio.com/comunidad/ecobici-expande-servicio-iztapalapa-iztacalco-tlalpan>, 2026, 28 de agosto de 2026.
- [4] T. Raviv, M. Tzur, and I. A. Forma, “Static repositioning in a bike-sharing system: models and solution approaches,” *EURO Journal on Transportation and Logistics*, vol. 2, no. 3, pp. 187–229, 2013.
- [5] D. Chemla, F. Meunier, and R. Wolfler Calvo, “Bike sharing systems: Solving the static rebalancing problem,” *Discrete Optimization*, vol. 10, no. 2, pp. 120–146, 2013.
- [6] M. Dell’Amico, E. Hadjicostantinou, M. Iori, and S. Novellani, “The bike sharing rebalancing problem: Mathematical formulations and benchmark instances,” *Omega*, vol. 45, pp. 7–19, 2014.
- [7] J. Schuijbroek, R. C. Hampshire, and W.-J. van Hoeve, “Inventory rebalancing and vehicle routing in bike sharing systems,” *European Journal of Operational Research*, vol. 257, no. 3, pp. 992–1004, 2017.
- [8] T. Raviv and O. Kolka, “Optimal inventory management of a bike-sharing station,” *IIE Transactions*, vol. 45, no. 10, pp. 1077–1093, 2013.
- [9] E. O’Mahony and D. Shmoys, “Data analysis and optimization for (Citi)Bike sharing,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 29, 2015.
- [10] J. Shu, M. C. Chou, Q. Liu, C.-P. Teo, and I.-L. Wang, “Models for effective deployment and redistribution of bicycles within public bicycle-sharing systems,” *Operations Research*, vol. 61, no. 6, pp. 1346–1359, 2013.
- [11] D. Zhang, C. Yu, J. Desai, H. Y. K. Lau, and S. Srivathsan, “A time-space network flow approach to dynamic repositioning in bicycle sharing systems,” *Transportation Research Part B: Methodological*, vol. 103, pp. 188–207, 2017.
- [12] B. Legros, “Dynamic repositioning strategy in a bike-sharing system; how to prioritize and how to rebalance a bike station,” *European Journal of Operational Research*, vol. 272, no. 2, pp. 740–753, 2019.
- [13] J. Brinkmann, M. W. Ulmer, and D. C. Mattfeld, “Dynamic lookahead policies for stochastic-dynamic inventory routing in bike sharing systems,” *Computers & Operations Research*, vol. 106, pp. 260–279, 2019.
- [14] J. Liang, S. D. Jena, and A. Lodi, “Dynamic rebalancing optimization for bike-sharing systems: A modeling framework and empirical comparison,” *European Journal of Operational Research*, vol. 317, no. 3, pp. 875–889, 2024.
- [15] M. Dell’Amico, M. Iori, S. Novellani, and A. Subramanian, “The bike sharing rebalancing problem with stochastic demands,” *Transportation Research Part B: Methodological*, vol. 118, pp. 362–380, 2018.
- [16] Y. Li, Y. Zheng, H. Zhang, and L. Chen, “Traffic prediction in a bike-sharing system,” in *Proceedings of the 23rd SIGSPATIAL International Conference on Advances in Geographic Information Systems*, 2015, pp. 1–10.
- [17] L. Chen, D. Zhang, L. Wang, D. Yang, X. Ma, S. Li, Z. Wu, G. Pan, T.-M.-T. Nguyen, and J. Jakubowicz, “Dynamic cluster-based over-demand prediction in bike sharing systems,” in *Proceedings of the 2016 ACM International Joint Conference on Pervasive and Ubiquitous Computing*, 2016, pp. 841–852.
- [18] A. Negahban, “Simulation-based estimation of the real demand in bike-sharing systems in the presence of censoring,” *European Journal of Operational Research*, vol. 277, no. 1, pp. 317–332, 2019.
- [19] C. Médard de Chardon, G. Caruso, and I. Thomas, “Bike-share rebalancing strategies, patterns, and purpose,” *Journal of Transport Geography*, vol. 55, pp. 22–39, 2016.
- [20] H. Luo, R. Sun, Z. Kou, and H. Cai, “Estimating rebalancing activities and vehicle use for existing station-based bike share systems,” *Transportation*, 2026, publicado en línea el 17 de abril de 2026.
- [21] A. Coronado Narváez, “Instrumentos y algoritmos para resolver el problema de rebalanceo en los sistemas de préstamo de bicicletas,” Tesis de Maestría en Ciencias en Computación, Instituto Tecnológico Autónomo de México, 2018, asesor: Adrián Ramírez Nafarrate.
- [22] H. R. Gómez Márquez, R. López Bracho, and A. Ramírez-

Nafarrate, “A simulation-optimization study of the inventory of a bike-sharing system: The case of Mexico city ecobici’s system,” *Case Studies on Transport Policy*, vol. 9, no. 3, pp. 1059–1072, 2021.

- [23] E. Possani and E. Castillo, “Optimizing the inventory and routing decisions in a bike-sharing system: A linear programming and stochastic approach,” *Case Studies on Transport Policy*, vol. 9, no. 4, pp. 1495–1502, 2021.
- [24] Ecobici and SEMOVI, “Datos abiertos de Ecobici: viajes,” <https://ecobici.cdmx.gob.mx/datos-abiertos/>, 2025, licencia CC-BY-4.0. Archivos mensuales 2025-01 a 2025-11. Consultado el 2026-09-29.
- [25] MobilityData, “General bikeshare feed specification (GBFS),” <https://github.com/MobilityData/gbfs>, 2026, feed de Ecobici: <https://gbfs.mex.lyftbikes.com/gbfs/gbfs.json>. Consultado el 2026-09-29.
- [26] M. Halford, “bike-sharing-history,” <https://github.com/MaxHalford/bike-sharing-history>, 2023, repositorio creado el 2023-07-02; archivos Parquet de Ecobici desde abril de 2024. Consultado el 2026-09-29.
- [27] V. Satopää, J. Albrecht, D. Irwin, and B. Raghavan, “Finding a “kneedle” in a haystack: Detecting knee points in system behavior,” in *2011 31st International Conference on Distributed Computing Systems Workshops*, 2011, pp. 166–171.
- [28] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM: A highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017, pp. 3146–3154.
- [29] Q. Huangfu and J. A. J. Hall, “Parallelizing the dual revised simplex method,” *Mathematical Programming Computation*, vol. 10, no. 1, pp. 119–142, 2018.
- [30] J. Deli, “movilidad-cdmx: rebalanceo de Ecobici con información asimétrica (código, app e instrucciones de instalación y ejecución),” <https://github.com/Jero110/movilidad-cdmx>, 2026, repositorio público del proyecto.

APÉNDICE A

FORMULACIÓN DEL ASIGNADOR

Sea $\mathcal{I}$ el conjunto de estaciones y t la hora de decisión (05:30, 05:45, ...; sin órdenes con $t + L \geq 00:30$). Del estado en t se toman b_i bicis disponibles y $K_i = b_i + \text{libres}_i$ (las dañadas y los anclajes deshabilitados no cuentan). La emisión de pronóstico más reciente con hora $\leq t$ da tasas por minuto $d_{i\tau}$ (salidas) y $a_{i\tau}$ (llegadas), uniformes en cada bloque de 60 min.

Proyección. $s_{i,\tau+1} = \text{clip}_{[0, K_i]}(s_{i\tau} + a_{i\tau} - d_{i\tau} + o_{i\tau})$ desde $s_{it} = b_i$ hasta $t + L$, con o las órdenes pendientes; $p_i = s_{i,t+L}$ y $\hat{p}_i = \text{round}(p_i)$.

Costo por estación. Para $y \in \{0, \dots, K_i\}$, se corre el mismo flujo desde $s_{i,t+L} = y$ hasta $t + L + h$ y $c_i(y) = \sum_{\tau} \mathbf{1}[s_{i\tau} < 0.5] + \mathbf{1}[s_{i\tau} > K_i - 0.5]$. Sobre el rango permitido $[\hat{p}_i - r_i, \hat{p}_i + u_i]$ se usa la envolvente convexa inferior $\hat{c}_i$, con vértices $a_0 < \dots < a_n$ y pendientes $\beta_{ik} = (c_i(a_{k+1}) - c_i(a_k))/(a_{k+1} - a_k)$, lo que hace lineal el objetivo.

Cotas. $\sigma_i = (\sum_{\tau \in [t, t+L)} (d_{i\tau} + a_{i\tau}))^{1/2}$, $r_i = \text{clip}_{[0, \hat{p}_i]} \min(\lfloor p_i - \sigma_i \rfloor, 22)$ y $u_i = \text{clip}_{[0, K_i - \hat{p}_i]} \min(K_i - \lfloor p_i + \sigma_i \rfloor, 22)$; las estaciones fuera de servicio tienen $r_i = u_i = 0$. Tope por hora: $M_t = 246 - \max_{V \ni t+L} |\{\text{órdenes con efecto en } V\}|$, sobre ventanas V de 60 min que empiezan cada 15 min. Bodega: con $W = A - R$ aplicado hasta t y $P = \text{suma de pendientes}$, $\ell_t = \min(-632 - W - P, 0)$ y $h_t = \max(632 - W - P, 0)$.

Solución. HiGHS con brecha relativa 10^{-4} . Si no hay solución factible, no se mueve nada y se registra (0 casos en el run 2). $\mu = 1$ minuto-estación por bici de bodega (sensibilidad $\mu = 0$).

Validación del sustituto. En 72 decisiones (3 días de selección $\times 8$ horas $\times h \in \{1, 3, 6\}$), la correlación de Spearman entre el costo sustituto y E+F de un simulador de flujo, sobre 23 planes por decisión, tiene mediana 0.977 y es ≥ 0.8 en 69 de 72 (ecosim/results/asignador/REPORT.md).

APÉNDICE B

RUN 1 CONTRA RUN 2 (MAÑANA)

Tabla VII: E+F de 05:30 a 12:30 (miles), mismos 15 días. El run 1 eligió su configuración en esos mismos días.

Brazo	Run 1	Config. run 1	Run 2 (mañana)
Sin rebalanceo	72.5		74.6
Ecobici	34.3		38.6
oracle	13.8	H=3	12.0
daily	19.6	H=3, bloque 30	16.4
ma	18.8	H=3	19.0
model	18.9	H=3	18.7